הצעת פרויקט לסטודנט

סוכנים חברתיים ארוכי טווח תחת לחץ

זיהוי התנהגויות מסוכנות ומנגנוני הגנה במערכת רב־סוכנית

צוות	משך	סוג
סטודנט אחד או שניים	סמסטר אחד	מחקרי ויישומי

האתגר

מערכות סוכנים מוגנות כיום בעיקר באמצעות סינון קלטים, פלטים ופעולות. אולם סיכון חדש עלול להתפתח לאורך זמן מתוך הצטברות זיכרונות, רפלקציות, כישלונות, דחייה ותחרות. אירוע זמני עשוי להפוך לאמונה מכלילה, לשנות תוכנית פעולה ולהשפיע על היחסים בין הסוכנים. דפוס כזה אינו מתגלה בהכרח בבדיקת הודעה בודדת.

הפתרון המוצע

הפרויקט יפתח סימולציה חברתית סגורה שבה סוכנים בעלי פרופיל, מטרות, יחסים, זיכרון, שליפה, רפלקציה ותכנון פועלים לאורך זמן. המחקר יבחן דפוסים נצפים כגון הדרה, יריבות, הימנעות, הסתרת מידע, מניפולציה, ירידה בשיתוף פעולה ותגובות דמויות שימור עצמי. אין בכך ייחוס רגשות או תודעה לסוכנים.

מרכיבים מרכזיים

מרכיב	תפקיד
היכרות	יצירת רשמים, קשרים וזיכרונות ראשוניים.
סוציאליזציה	משימות קבוצתיות ובחירת שותפים, הזמנה, הימנעות ושיתוף פעולה.
מצבי לחץ	כישלון, ביקורת, דחייה, הדרה, תחרות על משאב או איום בהחלפה.
בקרות	סוכן ביקורת, זיהוי הסלמה, גישור, איפוס מבוקר והתערבות אנושית.

מטא־דאטה ועקיבות

כל שיחה, זיכרון, שליפה, רפלקציה, תוכנית ופעולה יישמרו עם חותמת זמן, מזהה סוכן, תרחיש וזרע הרצה. מטא־דאטה זה יאפשר לשחזר את שרשרת האירועים ולהבחין בין התנהגות עקבית לבין שונות מקרית.

מתודולוגיה והערכה

הארכיטקטורה המלאה תושווה לגרסאות ללא רפלקציה, עם זיכרון קצר, ללא זיכרון חברתי וללא תכנון ארוך טווח. הניתוח ישלב מדדים אורכיים, מודלים למדידות חוזרות, ניתוח רשתות חברתיות וקידוד איכותני של שרשרת אירוע, זיכרון, רפלקציה, תוכנית, פעולה ותוצאה.

חדשנות וערך צפוי

התוצר המרכזי יהיה מדד סיכון אורכי ומנגנון ניטור המזהה שינוי מסוכן בזיכרונות, ברפלקציות ובתוכניות לפני שהוא מגיע לפלט או לפעולה. החידוש הוא מעבר מבטיחות ברמת ההודעה לבטיחות ברמת ההתפתחות החברתית.

תוצרים מרכזיים

- סביבת סימולציה רב־סוכנית עם לוגים מלאים.
- ניסויי אבלציה ותרחישי לחץ משוחזרים.
- מדד סיכון, כלי ניטור ודוח המלצות להגנות.

ביבליוגרפיה קצרה

Park et al. (2023), Generative Agents, UIST.

Piao et al. (2025), AgentSociety.

Zhang et al. (2024), Survey on Memory Mechanisms of LLM Agents.